


参数估计-极大似然估计

注意：极大似然估计的想法

找一个参数的值，使样本出现的可能性
达到最大

因为样本已经出现（无论是具体的数值，
还是具有表达式的小写 x_i ），那么我们倾
向于认为样本是以“较大概率”地方式
出现的（换句话说，小概率事件很难在
一次观测中出现）

既然样本已经出现，那就是比较大的概
率出现的



虽然不清晰总体的均值 $E(X)$ 是多少，但是直观上觉得红色的密度函数使数据出现的可能性大，而黑色的密度使数据出现的可能性小，因此更倾向于数据来自于红色密度

极大似然估计：数据出现的可能性达到最大

(1) 离散型样本 X_1, \dots, X_n 观测值为 x_1, \dots, x_n 找一个 λ

使数据出现的可能性达到最大，即关于 $L(\lambda)$ 找最大值（或极大值）：

$$L(\lambda) = \text{Likelihood}(\lambda) = P(X_1 = x_1, \dots, X_n = x_n) = \prod_{k=1}^n P(X_k = x_k, \lambda)$$

当 $\lambda = \hat{\lambda}$ 时， $L(\lambda)$ 达到最大（极大）， $\hat{\lambda}$ 就是参数 λ 的极大似然估计

(2) 连续型样本 X_1, \dots, X_n ，观测值为 x_1, \dots, x_n 数据出现的

可能性 $L(\theta) = \text{Likelihood}(\theta) = \prod_{k=1}^n f(x_k, \theta)$ ，关于 $L(\theta)$ 找最大值

（或极大值）使数据出现的可能性达到最大。

当 $\theta = \hat{\theta}$ 时， $L(\theta)$ 达到最大（极大）， $\hat{\theta}$ 就是参数 θ 的极大似然估计

此时求解出来的往往是样本的函数，也就是统计量

什么时候求导，什么时候不能求导

(1) 密度函数（连续）或概率（离散）大于0的 x 区域，与未知参数无关，此时就可以求导

(2) 密度函数（连续）或概率（离散）大于0的 x 区域，与未知参数有关，此时往往不可以求导，需要对该参数考虑单调的方法找最大值。

例1: 可以求导

设 X 服从参数为 λ ($\lambda > 0$) 的泊松分布,
 X_1, X_2, \dots, X_n 是来自 X 的一个样本, 求 λ 的最大似然估计量.

解 因为 X 的分布律为

$$P\{X = x\} = \frac{\lambda^x}{x!} e^{-\lambda}, \quad (x = 0, 1, 2, \dots, n)$$

所以 λ 的似然函数为

$$L(\lambda) = \prod_{i=1}^n \left(\frac{\lambda^{x_i}}{x_i!} e^{-\lambda} \right) = e^{-n\lambda} \frac{\lambda^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n (x_i!)},$$

$$\ln L(\lambda) = -n\lambda + \left(\sum_{i=1}^n x_i \right) \ln \lambda - \sum_{i=1}^n (x_i!),$$

$$\text{令 } \frac{\mathrm{d}}{\mathrm{d}\lambda} \ln L(\lambda) = -n + \frac{\sum_{i=1}^n x_i}{\lambda} = 0,$$

$$\text{解得 } \lambda \text{ 的最大似然估计值 } \lambda = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x},$$

$$\lambda \text{ 的最大似然估计量为 } \hat{\lambda} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}.$$

这一估计量与矩估计量是相同的.

连续分布（正态分布）：求导方法

例2 对正态总体 $N(\mu, \sigma^2)$, $\vartheta=(\mu, \sigma^2)$ 是二维参数, 设有样本 x_1, x_2, \dots, x_n , 则似然函数及其对数分别为

$$\begin{aligned} L(\mu, \sigma^2) &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{(x_i - \mu)^2}{2\sigma^2}\right\} \\ &= (2\pi\sigma^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right\} \end{aligned}$$

$$\ln L(\mu, \sigma^2) = -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 - \frac{n}{2} \ln \sigma^2 - \frac{n}{2} \ln(2\pi)$$

将 $\ln L(\mu, \sigma^2)$ 分别关于两个分量求偏导并令其为0, 即得到似然方程组

$$\frac{\partial \ln L(\mu, \sigma^2)}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0$$

$$\Rightarrow \sum_{i=1}^n (x_i - \mu) = 0 \Rightarrow \sum_{i=1}^n x_i = n\mu, \Rightarrow \mu = \bar{x} \quad (6.1.9)$$

$$\frac{\partial \ln L(\mu, \sigma^2)}{\partial \sigma^2} = \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2 - \frac{n}{2\sigma^2} = 0 \quad (6.1.10)$$

$$\Rightarrow \sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$$

解此方程组，由(6.1.9)可得 μ 的极大似然估计为

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$$

将之代入(6.1.10)，得出 σ^2 的极大似然估计

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = s_n^2$$

利用二阶导函数矩阵（海塞矩阵）的非正定性可以说明上述估计使得似然函数取极大值（本教材无需计算）。

本例中极大似然估计与某些矩估计也是相同的

例3： 单调方法

设总体 X 在 $[a, b]$ 上服从均匀分布, 其中 a , b 未知, x_1, x_2, \dots, x_n 是来自总体 X 的一个样本值, 求 a, b 的最大似然估计量.

解 记 $x_{(1)} = \min(x_1, x_2, \dots, x_n),$
 $x_{(n)} = \max(x_1, x_2, \dots, x_n),$

X 的概率密度为

$$f(x; a, b) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b \\ 0, & \text{其它} \end{cases}$$

密度大于0的区域与位置的 a, b 有关

因为 $a \leq x_1, x_2, \dots, x_n \leq b$ 等价于 $a \leq x_{(1)}, x_{(n)} \leq b$,
作为 a, b 的函数的似然函数为

$$L(a, b) = \begin{cases} \frac{1}{(b-a)^n}, & a \leq x_{(1)}, b \geq x_{(n)} \\ 0, & \text{其它} \end{cases}$$

于是对于满足条件 $a \leq x_{(1)}, b \geq x_{(n)}$ 的任意 a, b 有

$$L(a, b) = \frac{1}{(b-a)^n} \leq \frac{1}{(x_{(n)} - x_{(1)})^n},$$

$L(a, b)$ 关于 a , 单调递增, 所以当 a 取到最大值的时候,
 $L(a, b)$ 关于 a 达到最大。

$L(a, b)$ 关于 b , 单调递减少, 所以当 b 取到最小值的时候,
 $L(a, b)$ 关于 b 达到最大。

即似然函数 $L(a, b)$ 在 $a = x_{(1)}$, $b = x_{(n)}$ 时
取到最大值 $(x_{(n)} - x_{(1)})^{-n}$,

a, b 的最大似然估计值

$$\hat{a} = x_{(1)} = \min_{1 \leq i \leq n} x_i, \quad \hat{b} = x_{(n)} = \max_{1 \leq i \leq n} x_i,$$

a, b 的最大似然估计量

$$\hat{a} = \min_{1 \leq i \leq n} X_i, \quad \hat{b} = \max_{1 \leq i \leq n} X_i .$$

连续分布（均匀分布）：单调方法

虽然求导函数是求极大似然估计最常用的方法，但并不是在所有场合求导都是有效的。

例4 设 x_1, x_2, \dots, x_n 是来自均匀总体

$U[0, \theta]$ (闭区间) 的样本，试求 θ 的极大似然估计。

$$\begin{aligned} L(\theta) &= \prod_{k=1}^n f(x_k, \theta) = \prod_{k=1}^n \begin{cases} \frac{1}{\theta} & 0 \leq x_k \leq \theta \\ 0 & \text{其他} \end{cases} = \begin{cases} \frac{1}{\theta^n} & 0 \leq x_1, \dots, x_n \leq \theta \\ 0 & \text{其他} \end{cases} \\ &= \begin{cases} \frac{1}{\theta^n} & 0 \leq \min\{x_1, \dots, x_n\} \leq \max\{x_1, \dots, x_n\} \leq \theta \\ 0 & \text{其他} \end{cases} = \begin{cases} \frac{1}{\theta^n} & 0 \leq x_{(1)} \leq x_{(n)} \leq \theta \\ 0 & \text{其他} \end{cases} \end{aligned}$$


似然函数

$$L(\theta) = \begin{cases} \frac{1}{\theta^n} & 0 \leq x_{(1)} \leq x_{(n)} \leq \theta \\ 0 & \text{其他} \end{cases}$$

要使 $L(\theta)$ 达到最大，首先一点是示性函数取值应该为1，其次是 $1/\theta^n$ 尽可能大。由于 $1/\theta^n$ 是 θ 的单调减函数，所以 θ 的取值应尽可能小，但示性函数为1决定了 θ 不能小于 $x_{(n)}$ ，由此给出 θ 的极大似然估计：

可看下图

$$\hat{\theta} = x_{(n)}$$



当 $\theta = x_{(n)}$ 时候，似然函数 $L(\theta)$ 达到最大值，因此 $x_{(n)}$ 是 θ 的最大似然估计（此时能取到最大值）

注意到，本例中，也不是不可以求导。找 θ 使得 $L(\theta)$ 达到最大，很明显 $\frac{1}{\theta^n} > 0$ 。因此最大值不可能在 $L(\theta)=0$ 处出现，

只需讨论 $x_{(n)} \leq \theta$ 范围内的 $L(\theta) = \frac{1}{\theta^n}$ ，取对数 $\ln L(\theta) = -n \ln \theta$ ，

$$\frac{dL(\theta)}{d\theta} = -\frac{n}{\theta} < 0 \text{ (不可能等于0, 严格小于0)}$$

由于导数 $\frac{dL(\theta)}{d\theta} < 0$, $\ln L(\theta)$ 严格单调递减，

在范围内 $x_{(n)} \leq \theta$ ，当 $\theta = x_{(n)}$ 时达到最大值。

实际上，很容易看出 $\frac{1}{\theta^n}$ 单调减，求导有点多此一举了。